

卫共流域数字孪生智能体

知识检索逻辑梳理文档

wg_agent / PageIndex 检索系统

一、两种检索方式

1. 向量检索 (Vector)

- 使用 ChromaDB 向量数据库存储文档节点的 embedding
- Embedding 模型: bge-m3 (通过 Ollama 部署在 10.20.2.135:11434)
- 检索流程: 用户查询 -> embedding -> ChromaDB 相似度搜索 -> 返回 top_k 个最相关节点
- 每个节点包含: doc_name, node_id, title, summary, score
- 支持多知识库并行检索 (search_multi_kb)

2. LLM 层进式检索 (LLM Hierarchical)

- 参考 PageIndex (VectifyAI) 的 Reasoning-based RAG 理念
- 让 LLM 阅读文档的树形目录结构, 通过推理定位相关节点
- 检索流程:
 - a) 加载文档的 _structure.json 树结构文件
 - b) 去掉 text 字段 (减少 token 消耗), 保留 node_id / title / summary
 - c) 将树结构 + 用户问题发送给 LLM (qwen3-4b)
 - d) LLM 推理返回最相关的 node_id 列表
 - e) 根据 node_id 从原始结构中提取完整内容
- LLM 配置: qwen3-4b, DashScope API (阿里云通义千问)
- 评分机制: 按排名赋分 (第1个=1.0, 第2个=0.9, 递减, 最低0.1)
- 支持并发处理多个文档 (asyncio.gather)

二、三层架构

第一层: PageIndex 检索引擎

- vector_index.py: 向量检索核心, 封装 ChromaDB 操作

- llm_retriever.py: LLM 层进式检索核心，封装 LLM 调用和树结构解析
- kb_manager.py: 知识库管理，维护 9 个知识库的路径和配置

第二层: API 服务 (PageIndex/api.py)

运行在端口 8502，提供 RESTful 接口:

接口	方式	说明
POST /query/raw	向量检索	纯向量检索，返回原始结果
POST /query/llm	LLM检索	纯 LLM 层进式检索
POST /query/compare	对比检索	同时执行两种检索并返回对比结果
POST /query	RAG问答	检索 + LLM 生成回答

请求体格式: {q: 查询文本, top_k: 返回数量, kb_ids: 知识库ID列表}

第三层: RAG 检索器 (src/rag/retriever.py)

- 智能体主项目的检索入口，封装 PageIndex 的两种检索方式
- retrieve(): 向量检索
- retrieve_llm(): LLM 层进式检索
- retrieve_compare(): 对比检索（并发执行两种方式）
- get_relevant_context(): 统一入口，根据 retrieval_mode 参数选择检索方式

三、前端交互

- PageIndex 前端 (Streamlit, app.py) 提供两个使用检索的 Tab:
 - Tab1 智能对话: 支持选择 向量检索 / LLM检索 / 检索对比
 - Tab5 知识检索: 支持选择 向量检索 / LLM检索 / 检索对比
- 检索对比模式使用双栏布局 (st.columns(2)) 并排展示两种结果
- 智能体主项目通过 RAGRetriever 调用，默认使用 .env 中 DEFAULT_RETRIEVAL_MODE 配置

四、配置项

配置项	位置	说明
OPENAI_API_KEY	PageIndex/.env	LLM API 密钥（通义千问）
OPENAI_API_BASE	PageIndex/.env	LLM API 地址
OPENAI_MODEL_NAME	PageIndex/.env	LLM 模型名 (qwen3-32b)
EMBEDDING_MODEL_NAME	PageIndex/.env	Embedding 模型 (bge-m3)
EMBEDDING_MODEL_API_URL	PageIndex/.env	Ollama 服务地址
LLM_RETRIEVAL_API_KEY	PageIndex/.env	LLM检索专用密钥

LLM_RETRIEVAL_API_BASE	PageIndex/.env	LLM检索专用API地址
LLM_RETRIEVAL_MODEL_NAME	PageIndex/.env	LLM检索模型 (qwen3-4b)
DEFAULT_RETRIEVAL_MODE	.env (项目根)	默认检索方式 (vector/llm)

五、数据流向

向量检索数据流:

用户查询 -> RAGRetriever.retrieve() -> MultiKBVectorIndex.search_multi_kb() -> ChromaDB 相似度搜索 -> 加载 _structure.json 获取完整文本 -> 返回结果

LLM 检索数据流:

用户查询 -> RAGRetriever.retrieve_llm() -> LLMRetriever.search() -> 加载 _structure.json 树结构 -> 去掉 text 字段 -> 发送给 LLM 推理 -> 返回 node_id 列表 -> 从原始结构提取内容 -> 返回结果

对比检索数据流:

用户查询 -> RAGRetriever.retrieve_compare() -> asyncio.gather(向量检索, LLM检索) -> 并行执行 -> 返回两组结果

六、知识库列表

知识库ID	名称
catchment_basin	流域概况
water_project	水利工程
monitor_site	监测站点
history_flood	历史洪水
flood_preplan	防洪预案
system_function	系统功能
hydro_model	水文模型
catchment_planning	流域规划
project_designplan	工程设计